

Árvore de Decisão vs Rede Neural MLP

Este repositório contém o trabalho referente ao 2º bimestre da disciplina de Inteligência Artificial. O projeto treina e compara dois modelos de IA, sendo eles: **Árvore de Decisão** e **Rede Neural MLP**. Os modelos foram treinados para prever se um paciente possui doença cardíaca a partir de seus dados clínicos a partir do **dataset** [Heart Disease](#).

Integrantes

- Gabriel Rodrigues - RA: 23038182-2
 - Henrique Pacheco - RA: 23293915-2
 - Hugo Zuin - RA: 23000248-2
-

Estrutura do projeto

```
cardioML/
├── data/
│   └── dataset.csv          # Dataset (baixado automaticamente)
├── src/
│   ├── config.py           # Caminhos e constantes centralizadas
│   ├── dataset.py          # Carga e preparação dos dados
│   ├── train.py            # Treinamento dos modelos
│   ├── metrics.py         # Cálculo das métricas
│   ├── plots.py           # Geração dos gráficos
│   └── pipeline.py        # Orquestração das etapas
├── models/
│   ├── decision_tree.pkl   # Árvore de Decisão treinada
│   ├── mlp_classifier.pkl  # Rede Neural treinada
│   └── scaler.pkl          # Normalizador
├──
│   ├── comparacao.png      # Caminhos e constantes centralizadas
│   ├── grafico_arvore.png  # Carga e preparação dos dados
│   ├── grafico_correlacao.png # Treinamento dos modelos
│   ├── grafico_distribuicao.png # Cálculo das métricas
│   ├── grafico_redeNeural.png # Caminhos e constantes centralizadas
│   └── matriz_arvore.png   # Gráficos gerados
├── main.py                 # Ponto de entrada
├── pyproject.toml
├── uv.lock
├── README.md
└── README.pdf
```

Como Executar

Usando uv

```
uv run python main.py
```

O script executa todo o fluxo automaticamente: prepara os dados, treina os modelos, gera os gráficos e exibe a comparação.

Observação: o dataset é baixado automaticamente na primeira execução e salvo em `data/dataset.csv`. Nas execuções seguintes, a cópia local é reutilizada (não é necessário internet novamente).

Projeto

Contextualização

Doenças cardiovasculares são a principal causa de morte no mundo, responsáveis por cerca de 17,9 milhões de óbitos anuais segundo a Organização Mundial da Saúde. O diagnóstico precoce é fundamental para aumentar as chances de tratamento, porém exames clínicos completos são custosos e nem sempre acessíveis.

Problema

Dado um conjunto de atributos clínicos de um paciente (idade, pressão arterial, colesterol, frequência cardíaca, entre outros), é possível prever se esse paciente possui doença cardíaca?

Hipótese

Modelos de Inteligência Artificial treinados sobre dados clínicos conseguem classificar com boa acurácia pacientes com e sem doença cardíaca, podendo servir como ferramenta de apoio à triagem médica.

Métodos de IA Utilizados



- **Árvore de Decisão:** modelo supervisionado e interpretável, baseado em regras de decisão.
 - **Rede Neural MLP (Perceptron Multicamadas):** rede neural com camadas totalmente conectadas e maior capacidade de generalização.
-

Dataset


Atributo	Descrição
age	Idade do paciente (anos)
sex	Sexo (1 = masculino, 0 = feminino)
cp	Tipo de dor no peito (0–3)
trestbps	Pressão arterial em repouso (mmHg)
chol	Colesterol sérico (mg/dl)
fbs	Glicemia em jejum > 120 mg/dl
restecg	Resultado do ECG em repouso (0–2)
thalach	Frequência cardíaca máxima atingida
exang	Angina induzida por exercício
oldpeak	Depressão ST induzida por exercício
slope	Inclinação do segmento ST (0–2)
ca	Número de vasos coloridos por fluoroscopia (0–3)
thal	Tipo de talassemia (1–3)
target	Variável alvo (1 = possui doença, 0 = sem doença)

- **Origem:** Cleveland Heart Disease Dataset, do repositório UCI Machine Learning. O dataset é baixado automaticamente via URL pública. Fonte original: <https://archive.ics.uci.edu/dataset/45/heart+disease>
- **Quantidade de registros:** 303 amostras
- **Atributos:** 13 features + 1 variável alvo
- **Variável alvo:** `target` (1 = possui doença, 0 = não possui) — 165 pacientes com doença e 138 sem doença
- **Tratamento dos dados:** o dataset não possui valores nulos. As features foram normalizadas com `StandardScaler`, ajustado apenas no conjunto de treino para evitar vazamento de dados.
- **Divisão treino/teste:** 80% para treino (242 amostras) e 20% para teste (61 amostras), de forma estratificada para manter a proporção das classes.

Distribuição da variável Alvo



Matriz de Correlação




Treinamento dos Modelos

Árvore de Decisão


Algoritmo que divide os dados em regiões com base em regras sobre os atributos. É fácil de interpretar, pois cada caminho da raiz até uma folha representa uma sequência de decisões.

Parâmetros: `max_depth=5` `min_samples_split=10` `min_samples_leaf=5` ,



Matriz de confusão:

Matriz de Confusão — Árvore de Decisão




Rede Neural MLP

Rede neural com três camadas ocultas (64, 32 e 16 neurônios), função de ativação ReLU e otimizador Adam. As features são normalizadas antes do treinamento.

Parâmetros: `hidden_layer_sizes=(64, 32, 16)` `activation=relu` `solver=adam` ,
`early_stopping=True.`

Curva de perda e matriz de confusão:



Modelos Treinados

Após a execução são gerados:

- models/decision_tree.pkl
- models/mlp_classifier.pkl
- models/scaler.pkl


Esses arquivos podem ser reutilizados sem necessidade de novo treinamento.

Avaliação e Comparação dos Modelos

As métricas utilizadas foram acurácia, precisão, revocação (recall) e F1-score, calculadas sobre o conjunto de teste.

Métrica	Árvore de Decisão	Rede Neural (MLP)	Melhor
Acurácia	0.7541	0.8525	Rede Neural
Precisão	0.7250	0.8000	Rede Neural
Recall	0.8788	0.9697	Rede Neural
F1-Score	0.7945	0.8767	Rede Neural

Comparação Gráfica



Conclusão

A **Rede Neural MLP** apresentou o melhor desempenho em todas as métricas avaliadas: acurácia de 85,25%, precisão de 80,00%, recall de 96,97% e F1-score de 87,67%. O recall elevado é especialmente relevante na área médica, pois significa que o modelo identificou quase todos os pacientes que realmente possuíam a doença, deixando pouquíssimos casos sem detecção (falsos negativos).

A **Árvore de Decisão**, embora tenha tido desempenho inferior nas métricas, oferece a vantagem de ser facilmente interpretável: é possível visualizar exatamente quais regras o modelo utiliza para classificar um paciente, o que pode ser útil para explicar as decisões a profissionais de saúde.

A hipótese foi confirmada: ambos os modelos conseguiram classificar pacientes com doença cardíaca a partir de dados clínicos, e a Rede Neural alcançou acurácia superior a 85%. Para esse problema, a Rede Neural se mostrou a melhor escolha, equilibrando alta capacidade de detecção (recall) com bom desempenho geral. A Árvore de Decisão permanece como uma alternativa válida quando a prioridade é a interpretabilidade do modelo.